

TruthLens

AI 생성 콘텐츠 판별 서비스

Product Requirements Document (PRD)

문서 버전	v1.0.0
작성일	2026년 6월 13일
기술 스택	Flask, MariaDB, Python
보안 등급	내부 배포용

1. 문서 개요

1.1 목적

본 문서는 AI 생성 콘텐츠 판별 서비스(이하 'TruthLens')의 제품 요구사항을 정의합니다. 서비스의 기능 범위, 기술 아키텍처, 비기능 요구사항 및 출시 로드맵을 포함하며, 개발팀, 기획팀, 이해관계자 간의 공통 기준 문서로 활용됩니다.

1.2 배경 및 문제 정의

생성형 AI 기술의 급속한 발전으로 인해 AI가 생성한 이미지, 영상, 텍스트가 범람하고 있습니다. 이로 인해 다음과 같은 사회적 문제가 대두되고 있습니다.

- 딥페이크 영상 및 AI 생성 이미지를 이용한 허위 정보 유포
- AI 생성 가짜 뉴스 및 논문을 통한 여론 조작 및 학술 신뢰성 훼손
- AI 생성 콘텐츠의 저작권 및 진위 여부에 대한 법적, 윤리적 분쟁 증가
- 일반 사용자가 AI 생성 콘텐츠를 진위 판별할 수 있는 도구의 부재

TruthLens는 이러한 문제를 해결하기 위해, 다양한 유형의 콘텐츠(영상, 이미지, 텍스트)에 대해 AI 생성 여부를 판별하고 관련 분석 정보를 제공하는 웹 서비스입니다.

1.3 목표

- 영상, 이미지, 텍스트(뉴스, 논문)에 대한 AI 생성 여부 판별 정확도 85% 이상 달성
- 판별 결과에 대한 근거 정보 및 신뢰 지표 시각화 제공
- 반복 요청에 대한 캐싱을 통해 응답 지연 최소화(캐시 히트 시 1초 이내)
- 논문 대상 요약 자동 생성 및 누락 인용 탐지 추가 기능 제공
- 동일 콘텐츠에 대한 집단 분석 요청 현황을 사용자에게 투명하게 공개

1.4 용어 정의

용어	정의
TruthLens	본 서비스의 프로젝트명. AI 생성 콘텐츠 판별 웹 서비스 전체를 지칭
딥페이크(Deepfake)	AI를 이용해 영상, 이미지 속 인물이나 내용을 조작한 합성 미디어
콘텐츠 해시	판별 요청된 콘텐츠의 고유 식별자. 동일 콘텐츠 재요청 판별에 활용
캐시(Cache)	반복 요청의 빠른 응답을 위해 이전 판별 결과를 저장하는 임시 저장소

용어	정의
신뢰 점수	AI 생성 가능성을 0~100% 척도로 나타낸 수치
가짜 뉴스	사실에 기반하지 않거나 의도적으로 왜곡된 뉴스 콘텐츠
인용 누락	논문 내에서 참조되었으나 참고문헌 목록에 빠진 출처 정보

2. 서비스 범위 및 대상 사용자

2.1 서비스 범위

TruthLens는 Flask 기반 웹 애플리케이션으로, 다음 판별 도메인을 지원합니다.

도메인	입력 방식	주요 기능
영상 판별	URL 입력 / 파일 업로드	AI 생성 영상 탐지, 딥페이크 검출, 신뢰 점수 제공
이미지 판별	파일 업로드	AI 생성 이미지 탐지, 픽셀 패턴 분석, 신뢰 점수 제공
뉴스 판별	URL 입력 / 텍스트 직접 입력	가짜 뉴스 여부 탐지, 출처 신뢰도 분석
논문 판별	파일 업로드 (PDF)	AI 생성 논문 탐지, 자동 요약, 누락 인용 탐지 및 추가

2.2 대상 사용자(Persona)

2.2.1 일반 사용자

- 소셜 미디어에서 접한 이미지 영상의 진위를 빠르게 확인하고 싶은 일반인
- 딥페이크 피해 예방에 관심 있는 미디어 리터러시 교육 수요자

2.2.2 전문 사용자

- 뉴스 진위 확인이 필요한 언론인, 팩트체커
- 논문의 AI 생성 여부 및 인용 검증이 필요한 학술 연구자, 대학 교수, 학술지 편집자

2.2.3 기업/기관 사용자

- 콘텐츠 검수가 필요한 SNS 플랫폼, 미디어 기업
- 학술 진실성 검증이 필요한 대학 기관

2.3 서비스 제외 범위 (Out of Scope)

- 실시간 라이브 스트리밍 영상에 대한 판별
- 오디오 전용 파일(MP3, WAV 등)에 대한 AI 생성 판별
- 모바일 네이티브 앱(iOS/Android)
- 다국어 UI (초기 출시는 한국어 단일 지원)

3. 기능 요구사항(Functional Requirements)

FR-01 · 영상 AI 생성 판별

3.1.1 기능 설명

사용자가 영상 URL 또는 영상 파일을 업로드하면 시스템이 해당 영상의 AI 생성 여부를 분석하고 결과를 반환합니다.

3.1.2 세부 요구사항

- **자원 플랫폼:** URL 입력
 - YouTube, Vimeo URL 직접 입력 지원
 - 직접 영상파일 링크(mp4, avi, mov, webm) URL 지원
- **자원 형식:** 파일 업로드
 - MP4, AVI, MOV, WEBM 형식 지원
 - 최대 업로드 파일 크기 500MB
 - 최대 영상 길이 10분
- **판별 결과 제공 항목:**
 - AI 생성 가능성 신뢰 점수(0~100%)
 - 딥페이크 여부 탐지 결과
 - 프레임 단위 분석 하이라이트(의심 구간 타임스탬프)
 - 판별 근거 요약 텍스트

3.1.3 사용자 흐름(User Flow)

URL 입력 또는 파일 업로드 → 업로드 유효성 검사 → 콘텐츠 해시 생성 → 캐시 조회 → [캐시 히트 즉시 결과 반환]
[캐시 미스 분석 처리] → 결과 저장 및 표시

FR-02 · 이미지 AI 생성 판별

3.2.1 기능 설명

사용자가 이미지를 업로드하면 AI 생성 이미지 여부를 판별하고 시각적 분석 결과를 제공합니다.

3.2.2 세부 요구사항

- **자원 형식:** JPG, JPEG, PNG, WebP, GIF (정지 이미지)
- **최대 파일 크기:** 20MB
- **다중 이미지 동시 업로드 지원:** (최대 10장)

- 판별 결과 제공 항목
 - AI 생성 가능성 신뢰 점수(0~100%)
 - 히트맵(Heatmap) 시각화 AI 생성 의심 영역 표시
 - 픽셀 패턴 이상 탐지 결과
 - EXIF 메타데이터 분석 결과(생성 도구 정보 포함 시 표시)
 - 유사 AI 생성 이미지 참고 사례(옵션)

FR-03 · 뉴스 기사 판별

3.3.1 기능 설명

뉴스 기사 URL 또는 텍스트를 입력받아 해당 콘텐츠의 AI 생성 여부 및 가짜 뉴스 가능성을 분석합니다.

3.3.2 세부 요구사항

- 입력 방식: 뉴스 URL 입력, 텍스트 직접 붙여넣기(최대 10,000자)
- 판별 결과 제공 항목
 - AI 생성 텍스트 가능성 점수
 - 가짜 뉴스 가능성 점수
 - 출처 신뢰도 분석(도메인 기반)
 - 감성 편향 분석(중립 편향 판단)
 - 주요 의심 문장 하이라이트
 - 유사 사실 확인 기사 링크 제공(외부 팩트체크 DB 연동)

FR-04 · 논문 AI 생성 판별 및 분석

3.4.1 기능 설명

PDF 형식의 논문을 업로드받아 AI 생성 여부 판별, 자동 요약, 누락 인용 탐지 및 추가 기능을 제공합니다.

3.4.2 세부 요구사항

- 입력 방식: PDF 파일 업로드(최대 50MB, 최대 200페이지)
- AI 생성 판별
 - 논문 전체 AI 생성 가능성 점수
 - 섹션별(서론/방법론/결론 등) AI 생성 비율 시각화
 - AI 생성 의심 문단 하이라이트
- 자동 요약 기능
 - 논문 전체 요약(500자 이내)

- 핵심 주장 3~5개 항목 추출
- 연구 방법론 요약
- 인용 분석 기능
 - 본문 내 인용 표시 탐지(예 [1], (Smith, 2020))
 - 참고문헌 목록과 본문 인용 교차 검증
 - 누락 인용 목록 탐지 및 사용자에게 안내
 - 누락 인용에 대한 메타데이터 자동 검색(DOI, 저자, 제목)
 - 사용자 확인 후 수정된 PDF 다운로드 가능

FR-05 · 캐싱 및 동일 콘텐츠 집계 표시

3.5.1 기능 설명

동일 콘텐츠에 대한 판별 요청이 단기간에 집중될 경우 캐싱을 통해 빠른 응답을 제공하고, 결과 페이지에서 해당 콘텐츠를 분석 요청한 사용자 수를 표시합니다.

3.5.2 세부 요구사항

- 캐시 트리거 조건 동일 콘텐츠 해시에 대해 1시간 이내 100회 이상 요청 발생 시 캐시 활성화
- 캐시 저장소 Redis (인메모리 캐시) 활용
- 캐시 유효 기간(TTL): 기본 24시간, 트랜딩 콘텐츠는 자동 연장
- 콘텐츠 해시 생성 방식
 - 영상 이미지: 파일 SHA-256 해시 또는 퍼셉추얼 해시(pHash)
 - 텍스트/URL: URL 정규화 후 MD5 해시
- 결과 페이지 표시 항목
 - '이 콘텐츠를 분석한 사용자 수: N명 실시간 표시
 - 최근 24시간 요청 추이 차트 (선택적 표시)
 - 캐시 결과임을 나타내는 배지 표시 ('빠른 결과 제공 중')
- 캐시 마적용 시 실시간 분석 처리 후 결과 저장 및 캐시 등록

4. 비기능 요구사항(Non-Functional Requirements)

4.1 성능

항목	목표 수치	비고
이미지 판별 응답 시간	5초 이내	일반 조건
영상 판별 응답 시간	2분 이내(5분 영상 기준)	비동기 처리
캐시 히트 응답 시간	1초 이내	Redis 캐시 적중 시
뉴스논문 텍스트 분석	10초 이내	최대 10,000자 기준
동시 접속자 처리	500명 이상	초기 출시 기준
서비스 가용성(Uptime)	99.5% 이상	월간 기준

4.2 보안

- 사용자 업로드 파일 악성코드 스캔 후 임시 저장소에 저장, 분석 완료 후 72시간 내 삭제
- API 통신 HTTPS(TLS 1.2+) 적용 필수
- 파일 업로드 검증: 파일 확장자 및 MIME 타입 이중 검증, 파일 크기 제한 서버 사이드 강제
- Rate Limiting: IP당 분당 최대 20회 요청 제한(DoS 방지)
- SQL Injection 방지: SQLAlchemy ORM 사용, 파라미터화 쿼리 적용
- 개인정보 판별 요청 시 사용자 개인식별정보 최소 수집 원칙

4.3 확장성

- 마이크로서비스 분리 가능 구조: 판별 도메인별(영상/이미지/텍스트) AI 모델 모듈화
- AI 모델 교체 가능 설계: 모델 인터페이스 추상화로 향후 모델 업그레이드 용이
- 수평 확장(Horizontal Scaling) 지원: Flask 애플리케이션 Gunicorn + Nginx 구성

4.4 유지보수성


- 코드 커버리지 70% 이상 달성(pytest 기반 단위/통합 테스트)
- API 문서 자동 생성: Flask-RESTX 또는 Flasgger를 통한 Swagger UI 제공
- 에러 로깅: Sentry 연동 또는 자체 구조화 로그(JSON 형식) 저장

5. 기술 아키텍처

5.1 기술 스택

레이어	기술	역할
Frontend	HTML5, CSS3, JavaScript (Vanilla / Alpine.js)	UI 렌더링, 파일 업로드, 결과 시각화
Backend	Python 3.11+, Flask 3.x	API 라우팅, 비즈니스 로직, 파일 처리
AI 분석	Transformers, OpenCV, PyTorch	AI 생성 콘텐츠 탐지 모델 실행
Database	MariaDB 11.x	판별 결과, 요청 이력, 콘텐츠 메타데이터 저장
Cache	Redis 7.x	콘텐츠 판별 결과 캐싱, 요청 카운터
File Storage	로컬 파일시스템 / AWS S3 (확장)	업로드 파일 임시 저장
Task Queue	Celery + Redis	영상 등 장시간 처리 비동기 작업
Web Server	Gunicorn + Nginx	운영 환경 서비스 배포

5.2 시스템 구성도



5.3 주요 DB 테이블 설계

테이블명	주요 컬럼	설명
detection_requests	id, content_hash, type, status, created_at	판별 요청 이력 저장
detection_results	request_id, score, detail_json, cached, created_at	판별 결과 저장
content_stats	content_hash, request_count, last_requested_at	콘텐츠별 요청 통계
paper_citations	request_id, citation_ref, status, doi, title	논문 인용 분석 결과
cache_metadata	content_hash, ttl, hit_count, activated_at	캐시 활성화 이력

5.4 배포 환경 (클라우드타입)

TruthLens는 클라우드타입(cloudtype.io)을 배포 플랫폼으로 사용합니다. 클라우드타입은 GitHub 연동 기반의 한국 클라우드 애플리케이션 플랫폼으로, 복잡한 인프라 설정 없이 Flask 애플리케이션을 빠르게 배포하고 운영할 수 있습니다.

5.4.1 배포 환경 구성

환경	클라우드타입 Stage	용도
개발 (Dev)	dev	기능 개발 및 단위 테스트 개발팀 내부 접근 전용
스테이징 (QA)	qa	통합 테스트 및 QA 검증 운영 환경과 동일한 구성으로 최종 검증
운영 (Production)	main	실 사용자 대상 서비스 GitHub main 브랜치 병합 시 자동 배포

5.4.2 배포 서비스 구성

클라우드타입 프로젝트 내에 다음 서비스를 독립적으로 배포하며, 동일 배포 환경 내에서 서비스명을 hostname으로 상호 통신합니다.

- Flask App — Python 3.11 기반 웹 애플리케이션 서버 (Gunicorn)
- Celery Worker — 영상 등 장시간 비동기 분석 작업 처리
- MariaDB — 클라우드타입 제공 데이터베이스 서비스로 즉시 설치 및 연결
- Redis — 클라우드타입 제공 캐시 서비스로 즉시 설치 및 연결

5.4.3 CI/CD 자동화

- GitHub 저장소 연동: OAuth 기반으로 GitHub 저장소와 클라우드타입 프로젝트 연결
- 자동 배포: GitHub 브랜치에 코드 푸시 시 클라우드타입이 자동으로 빌드 및 배포 실행
- GitHub Actions 연동: 테스트 통과 후 배포되도록 워크플로우 구성 (선택)
- 환경 변수 관리: API 키, DB 접속 정보 등 민감 정보는 코드에 포함하지 않고 클라우드타입 프로젝트 환경 변수로 설정

5.4.4 배포 최소 요구사항

항목	사양	비고
Python	3.11 이상	Flask 3.x 호환 버전
MariaDB	11.x	클라우드타입 기본 제공 버전 사용
Redis	7.x	클라우드타입 기본 제공 버전 사용
클러스터 리전	Seoul	국내 사용자 응답 속도 최소화
Dockerfile	제공 (선택)	커스텀 빌드 환경이 필요한 경우 사용

6. UI/UX 요구사항

6.1 주요 화면 목록

화면	경로	주요 기능
메인(홈) 화면	/	서비스 소개, 판별 유형 선택
영상 판별	/detect/video	URL/파일 입력, 분석 진행 표시
이미지 판별	/detect/image	이미지 업로드, 다중 업로드
뉴스 판별	/detect/news	URL/텍스트 입력
논문 판별	/detect/paper	PDF 업로드, 요약/인용 분석
판별 결과	/result/:id	신뢰 점수, 상세 분석 집계 표시
판별 이력	/history	과거 요청 목록 및 결과 재조회

6.2 결과 화면 필수 요소

- 신뢰 점수 게이지(0~100%, 색상 코딩: 초록 = 실제, 노랑 = 의심, 빨강 = AI 생성 강력 의심)
- 판별 근거 요약 카드
- 동일 콘텐츠 분석 요청자 수: 'N명이 이 콘텐츠를 분석했습니다' 표시
- 캐시 결과 표시 배지: 빠른 결과 제공 중 (캐시 히트 시)
- 결과 공유 버튼 (URL 복사, SNS 공유)
- 분석 재요청 버튼

6.3 반응형 디자인

- 지원 해상도: 모바일(320px+), 태블릿(768px+), 데스크탑(1280px+)
- 모바일 환경에서 파일 업로드: 카메라 갤러리 접근 허용

7. API 설계

7.1 REST API 엔드포인트

Method	Endpoint	요청바디	설명
POST	/api/v1/detect/video	file or url	영상 AI 판별 요청
POST	/api/v1/detect/image	file(s)	이미지 AI 판별 요청
POST	/api/v1/detect/news	url or text	뉴스 기사 판별 요청
POST	/api/v1/detect/paper	file (PDF)	논문 AI 판별 요청
GET	/api/v1/result/:id	-	판별 결과 조회
GET	/api/v1/stats/:hash	-	콘텐츠별 요청 통계 조회
GET	/api/v1/paper/:id/citations	-	논문 인용 분석 결과 조회
POST	/api/v1/paper/:id/citations/add	citation_ids[]	선택 인용 추가 후 PDF 재생성
GET	/api/v1/history	-	요청 이력 조회

7.2 공통 응답 구조

모든 API 응답은 다음 JSON 구조를 따릅니다.

```
{ "status": "success|error", "data": { ... }, "meta": { "cached": true, "request_count": 142, "processing_time_ms": 312 } }
```

8. 제약사항 및 리스크

8.1 기술적 제약사항

- AI 판별 모델의 정확도 한계. 최신 생성형 AI로 만든 콘텐츠에 대한 오탐(False Negative) 발생 가능성 존재. 신뢰 점수와 함께 '참고용 정보임'을 사용자에게 명확히 안내 필요
- 영상 분석 처리 시간. 장시간 영상의 경우 수분 소요 가능. Celery 비동기 처리 및 진행 상태 실시간 표시(WebSocket 또는 Polling)로 UX 보완
- 외부 URL 접근 제한 robots.txt 차단, 로그인 필요 페이지 등 크롤링 불가 콘텐츠에 대한 예외 처리 필요

8.2 법적 윤리적 제약사항

- 판별 결과는 '참고 정보'로만 제공되며, 법적 증거 능력 없음을 서비스 약관에 명시
- 개인 얼굴이 포함된 답변/이미지 판별 결과에 대한 개인정보보호법 준수
- 논문 PDF 업로드 시 저작권 관련 면책 조항 동의 UI 필요

8.3 리스크 매트릭스

리스크	발생 가능성	영향도	대응 전략
AI 모델 오탐으로 인한 사용자 불만	높음	중간	신뢰 점수 + 면책 안내 강화
대용량 파일 업로드로 서버 과부하	중간	높음	파일 크기 제한, 비동기 큐 처리
캐시 데이터 오염으로 잘못된 결과 제공	낮음	높음	캐시 무효화 정책 및 주기적 검증
외부 AI API 의존성 장애	중간	높음	폴백(Fallback) 로컬 모델 확보
개인정보 포함 파일 무단 저장	낮음	매우 높음	분석 후 즉시 삭제 + 감사 로그

9. 출시 로드맵

단계	기간	포함 기능
Phase 1 MVP	~8주	이미지 AI 판별 (FR-02), 뉴스 텍스트 판별 기본 (FR-03), 기본 결과 페이지, MariaDB 스키마 구축
Phase 2 핵심 기능	~6주	영상 판별 (FR-01), 캐싱 시스템 (FR-05), 동일 콘텐츠 집계 표시, Celery 비동기 처리
Phase 3 논문 기능	~5주	논문 판별 및 요약 (FR-04), 누락 인용 탐지, PDF 재생성 다운로드
Phase 4 고도화	~4주	UI/UX 개선, 성능 최적화, 모바일 반응형 강화, 분석 이력 대시보드

10. 이해관계자 및 승인

역할	담당	책임 범위	승인 필요
Product Owner	-	요구사항 정의, 우선순위 결정	예
Tech Lead	-	아키텍처 설계, 기술 검토	예
Backend Dev	-	Flask API, DB, 캐시 구현	아니오
AI/ML Engineer	-	판별 모델 통합 및 최적화	아니오
Frontend Dev	-	UI 구현 결과 시각화	아니오
QA Engineer	-	테스트 설계 및 품질 검증	아니오

본 PRD는 프로젝트 착수 전 모든 이해관계자의 검토 및 승인이 완료되어야 합니다. 문서 변경 시 버전 이력을 관리하고, 주요 변경사항은 관련 팀에 사전 공지합니다.